
Morning Brief

基于大语言模型与状态图编排的智能晨报系统

包一鸣
2023012201
新雅31-计37
bao-ym23@mails.tsinghua.edu.cn

Abstract

本项目设计并实现了**Morning Brief**：一个本地优先、由大语言模型（LLM）驱动的自动化晨报智能体。系统每天清晨自动从arXiv、GitHub、Hacker News、RSS等多源采集信息，经过清洗去重、启发式粗排后，以**LLM-as-judge**的方式对每条候选信息进行打分、归类与价值评估，再由LLM完成版面规划与分栏摘要，最终渲染为HTML/Markdown晨报并通过邮件/飞书等渠道投递。我们将整个流程建模为一张显式的有向状态图（**LangGraph**），并提出一种“**启发式+神经推理**”混合管线：用确定性规则保证可复现与低成本，用LLM提供语义理解与编辑判断，并设计了条件回退分支与抽取式确定性兜底推理器，在LLM不可用或产出过严时仍能稳定出报。此外我们提出按来源轮转交错（*round-robin interleaving*）的多样性采样，缓解纯分数排序导致的“信息源垄断”。系统通过30余个单元/集成测试、**ruff**与**mypy -strict**静态检查，可零配置一键运行。

1 简介

1.1 研究问题与动机

我对前沿信息有强烈的获取需求：每天早上我都想快速了解arXiv上AI方向的新论文、我关注的GitHub仓库的更新、Hacker News的高热讨论以及若干技术博客的RSS更新。然而这些信息分散在不同平台，存在三个痛点：（1）**信息过载**——逐个平台刷一遍既耗时又容易遗漏；（2）**噪声高、信号弱**——大量低质内容（如HN的招聘贴、重复转载）淹没了真正重要的更新；（3）**缺乏个性化的“为什么值得看”**——传统RSS阅读器只做聚合与时间排序，不会告诉我“这条对我意味着什么”。

因此本项目的研究问题是：如何构建一个自动化的信息处理智能体，使其能够像一位称职的编辑一样，每天自动地从多源采集信息、判断价值、组织版面并生成一份高信噪比、带有解释性的个性化晨报？这一问题既有现实应用价值（研究者/工程师的日常信息获取），也契合本课程主题：它的“认知内核”正是一个大型神经网络（LLM），我们要研究的是如何把LLM作为可控、可靠的推理组件嵌入一个工程化的批处理系统。同时，在项目开发的过程中，我尝试从一个产品经理而非工程师的视角，大量使用Vibe Coding Agents（Claude Code / Codex等）进行软件开发，切身体会到了新一代软件开发的范式转变。

1.2 现有方法的缺陷

现有方案大致分两类。其一是**传统聚合器**（RSS阅读器、邮件newsletter）：它们只做抓取与时间/热度排序，没有语义层面的价值判断与摘要，无法回答“为什么重要”。其二是**纯LLM的“一把梭”方案**：把所有原始内容塞进一个超长prompt让LLM一次性产出晨报。后者看似简单，却存在严重缺陷：成本与延迟高、上下文窗口受限、输出不可控（结构、长度漂移）、不可复现、且一旦LLM接口故障整个系统即不可用，缺乏工程鲁棒性。

1.3 我们的方法与亮点

我们提出**Morning Brief**，将晨报生成建模为一张显式的有向状态图，并采用“**确定性启发式+神经语义推理**”的混合管线。核心亮点如下：

- **显式状态图编排 (LangGraph)**：把采集→清洗去重→启发式粗排→LLM 逐条评估→筛选→版面规划→分栏摘要→渲染→投递→落盘 建模为11 个节点的状态机，每步状态可观测、可落盘、可断点续跑 (checkpoint)。
- **LLM-as-judge 的逐条价值评估**：对每条候选信息，用LLM 在受约束的JSON 结构下输出重要性、新颖性、归类、目标读者、“为什么重要”以及是否收录，把LLM 的语义判断转化为可计算的结构化信号。
- **混合打分与分数融合**：将廉价的确定性启发式分数与昂贵的LLM 评估分数加权融合，兼顾可复现性、成本与语义质量。
- **鲁棒的优雅降级**：设计条件回退分支（入选过少时自动放宽阈值）与一个纯确定性的抽取式兜底推理器，使系统在无API Key 或LLM 故障时仍能完整出报——做到“零配置可运行”。
- **按来源轮转交错的多样性采样**：解决纯分数排序下arXiv 因高来源质量分而“垄断”整份晨报的问题。

工作量方面：项目包含约90 个Python 源文件、覆盖6 类信息源、3 种投递渠道、2 种推理器实现，配套30 余个测试，全部通过ruff 与mypy -strict 严格检查。

2 相关工作

大语言模型与指令跟随。本系统的语义内核是基于Transformer [8] 的大语言模型。自GPT-3 [2] 展示出强大的少样本能力、以及InstructGPT [6] 通过人类反馈强化学习使模型对齐指令以来，LLM [1] 已能稳定完成“按指定JSON 结构产出评估”这类受控生成任务，这正是我们让LLM 充当“编辑判官”的基础。我们借鉴了指令跟随与受约束解码的思想（要求response_format=json_object 并用Pydantic 校验），但不同于直接对话，我们把LLM 嵌入为管线中一个有明确输入输出契约的纯函数节点。

LLM 作为评估器 (LLM-as-a-judge)。Zheng 等人 [11] 系统研究了用强LLM 为候选回答打分的可行性与偏差。我们将这一范式从“评估模型回答”迁移到“评估信息条目的编辑价值”：让LLM 对每条arXiv/HN/GitHub 条目给出重要性、新颖性等评分。区别在于我们不依赖LLM 给出绝对正确的排序，而是把它的分数作为多信号融合中的一路，并叠加确定性启发式以降低单点偏差与抖动。

智能体与推理-行动框架。ReAct [10] 提出交错“推理”与“行动”，Toolformer [7] 让模型学会调用工具，思维链 [9] 提升多步推理质量。这些工作多采用由LLM 自主决定下一步的开放式智能体。我们的关键差异是：出于工程可控性与可复现性，我们不让LLM 决定流程走向，而是用一张人为设计的固定状态图 (LangGraph [3]) 来编排，仅在节点内部调用LLM。流程中唯一的“决策分支”（是否放宽筛选）也由确定性规则触发，而非LLM。这是一种“弱智能体、强工程”的折中，牺牲了一部分自主性，换来稳定、低成本与可调试性。

自动摘要。传统抽象式摘要以BART [4] 等序列到序列模型为代表；检索增强生成RAG [5] 强调以外部证据约束生成。我们的分栏摘要节点在精神上接近RAG：摘要严格基于已选条目的字段“接地”，prompt 明确要求“不得编造材料之外的事实”，以抑制幻觉。

3 方法

3.1 任务的形式化定义

设第 d 天系统从 K 个信息源采集到原始条目集合 $\mathcal{R}_d = \{r_1, \dots, r_N\}$ 。每条原始条目经归一化映射 ϕ 转换为统一的内容模型BriefItem:

$$x_i = \phi(r_i), \quad x_i = (\text{source}, \text{title}, \text{url}, \text{published_at}, \text{text}, \text{engagement}, \dots).$$

任务目标是学习/构造一个映射 $\mathcal{F}$ ，从条目集合生成一份结构化晨报 B_d ：

$$B_d = \mathcal{F}(\{x_1, \dots, x_N\}) = (\text{overview}, \{S_1, \dots, S_M\}),$$

其中每个栏目 $S_j = (\text{name}_j, \text{summary}_j, \mathcal{I}_j)$ ， $\mathcal{I}_j \subseteq \{x_i\}$ 为该栏目所含条目， $\{\mathcal{I}_j\}$ 互不相交。我们要求晨报满足：高价值（收录条目编辑价值高）、多样（来源均衡）、可解释（每条给出“why it matters”）、且生成过程鲁棒可复现。

我们将 $\mathcal{F}$ 分解为一条由11个算子构成的有向无环流水线（含一个条件分支），见图1。

3.2 系统总览：显式状态图

整个 $\mathcal{F}$ 被实现为一张LangGraph 状态图，共享一份带类型的状态字典`MorningBriefState`。每个节点是一个纯函数 $g : \text{State} \rightarrow \Delta\text{State}$ ，读取所需字段、产出增量更新并写出该阶段的JSON 快照（artifact）。图1给出整体结构。

3.3 信息源接入与RSS 桥接：X 与微信公众号

`ingest_sources` 节点通过一个组合源（`CompositeBriefSource`）统一调度 K 个连接器，每个连接器实现统一的`BriefSource.fetch` 接口，内部带指数退避重试与原始负载均衡，并将平台异构的原始数据经归一化映射 ϕ 统一为`BriefItem`。组合源对单个连接器失败做隔离：某一源抓取异常仅丢失该源条目，不影响其余源与整份晨报的生成。系统内置四个原生在线连接器——arXiv、GitHub 跟踪仓库事件、Hacker News、以及通用RSS/Atom——外加一个本地演示文件源。

动机：为什么不直接接入X 与微信公众号。 X（Twitter）与微信公众号是高价值信息源，但二者都缺乏稳定、低门槛的官方批量抓取方式：X 对未登录访问做激进封锁且API 政策频繁变动；微信公众号没有开放的文章列表API。若把脆弱的网页抓取与登录态管理硬编码进主管线，将直接违背本系统“弱智能体、强工程、可复现、鲁棒”的设计哲学（§3.7、§3.8），引入难以测试与维护的单点失败。

设计：桥接器（bridge）模式。 我们因此采用桥接解耦：把平台相关、易碎、需登录态的抓取逻辑外移到一个自托管的桥接服务，由它将目标平台内容重新发布为标准RSS/Atom，再交给我们稳定的rss 连接器消费。如此，主管线对具体平台零耦合，并完整复用rss 连接器既有的关键词过滤、去重、打分、多样性等下游能力。数据流如图2所示。

X（Twitter）管线。 自托管RSSHub（容器监听:1200）。由于X 封锁匿名访问，需在桥接侧配置TWITTER_AUTH_TOKEN（取自一个一次性小号登录后的`auth_token` cookie）。可用路由包括用户时间线`/twitter/user/:username/`、列表`/twitter/list/:id` 与关键词检索`/twitter/keyword/:keyword/`；将其产出的feed URL（如`http://localhost:1200/twitter/user/OpenAI`）追加进SOURCE_RSS_FEEDS 即可。

微信公众号管线。 自托管WeWe RSS（容器监听:4000），其通过绑定一个微信读书账号（手机扫码授权）来驱动公众号订阅；每个订阅的公众号会暴露一个`/feeds/<feed_id>.atom` 端点，同样追加进SOURCE_RSS_FEEDS。两套桥接均以docker-compose 形式随仓库提供（`deploy/rsshub/`、`deploy/wewe-rss/`），一键启动。

与多样性采样的协同。 桥接而来的X、微信公众号条目在rss 连接器内按`feed` 进一步细分为独立子通道，配合§3.10 的按来源轮转交错，可避免被来源质量分更高的arXiv 等淹没，在版面截断时仍获公平表达。

风险与限制。 二者均依赖登录态/账号（建议使用小号以隔离账号风险）；存在平台限流（WeWe RSS 以UPDATE_DELAY_TIME 拉开更新间隔）、会话过期需重新绑定等运维成本。作为未来工作，可在同一`BriefSource` 接口下实现原生`twitter_x.py` 连接器（见§5 与`docs/next-sources.md`），在具备稳定官方凭据时替代桥接、降低运维负担。

3.4 确定性启发式粗排

在调用昂贵的LLM 之前，我们先用确定性启发式对每条 x_i 打分，目的有二：（1）廉价地缩小候选集；（2）为后续LLM 评估提供先验信号。对条目 x_i ，最终启发式分数为五项加

权和:

$$\text{score}_{\text{heur}}(x_i) = w_r \rho(x_i) + w_e \eta(x_i) + w_q \sigma(x_i) + w_k \kappa(x_i) + w_t \tau(x_i),$$

各项含义与默认权重（见附录表 2）为:

- **时效性** $\rho(x_i) = \exp(-\Delta t_i/72)$, Δt_i 为发布距今小时数, 半衰约72 小时;
- **互动度** $\eta(x_i) = \min(\text{score}/250 + \text{comments}/150 + \text{stars}/5000 + \text{likes}/500, 1)$;
- **来源质量** $\sigma(x_i)$: arXiv= 1.0、GitHub= 0.9、HN= 0.75、RSS= 0.7 等先验;
- **关键词亲和** $\kappa(x_i)$: 标题/正文/标签命中优先关键词（如 *llm*, *reasoning*, *agents*）的比例;
- **主题亲和** $\tau(x_i)$: 依归类主题（AI research = 1.0、Open-source = 0.95 ...）赋权。

3.5 LLM-as-judge: 逐条结构化评估

这是系统的神经推理核心。对粗排候选池中的每条 x_i , 我们构造一段评估prompt（见附录 B），要求LLM 在 `json_object` 约束下输出一个结构化评估 e_i :

$$e_i = \left(\underbrace{m_i}_{\text{main_idea}}, \underbrace{a_i}_{\text{importance} \in [0,1]}, \underbrace{n_i}_{\text{novelty} \in [0,1]}, c_i^{\text{cat}}, \text{audience}_i, \underbrace{y_i}_{\text{why_it_matters}}, \underbrace{\text{inc}_i}_{\in \{0,1\}} \right).$$

返回内容由Pydantic 模型 `ItemEvaluation` 强校验（分数越界、字段缺失即判为非法），非法输出触发重试或回退。**设计要点**: 我们没有让LLM 直接输出“最终晨报”，而是只让它输出可计算、可校验、可融合的中间信号，从而把不可控的自由文本生成，约束为可控的结构化评估问题。

3.6 分数融合与筛选

我们不单独信任LLM，也不单独信任启发式，而是把二者融合。对每条候选定义筛选分数:

$$\text{sel}(x_i) = 0.45 a_i + 0.25 n_i + 0.30 \text{score}_{\text{heur}}(x_i),$$

并以阈值 θ （默认0.62）配合LLM 的 `include` 标志做收录决策: 当 $\text{sel}(x_i) \geq \theta$ 且 ($\text{inc}_i = 1$ 或处于回退模式)，或 $\text{sel}(x_i) \geq \theta + 0.08$ （高分强收）时收录。收录后条目的最终展示分进一步融合为

$$\text{final}(x_i) = 0.40 \text{score}_{\text{heur}}(x_i) + 0.35 a_i + 0.25 n_i.$$

这种多信号线性融合显著降低了对LLM 单点判断的依赖: 即便某次LLM 评分异常，启发式先验仍能纠偏。

3.7 条件回退: 保证“总能出报”

若按主阈值筛得的条目数少于下限 $L_{\min}$ （默认4），状态图的路由函数 `route_after_selection` 返回 `relax_selection` 分支，依次执行:（1）将阈值降到 $\theta_{\text{fb}} = 0.48$ 并允许覆盖 `include`;（2）若仍不足，则按 `final` 分数从候选池按来源交错补足至 $L_{\min}$ 。否则直接进入 `plan_brief`。该分支是流程中唯一的“决策点”，且由确定性规则而非LLM 触发，保证行为可预测。

3.8 版面规划与分栏摘要

`plan_brief` 让LLM 把已选条目组织为2-4 个连贯栏目并产出导语，输出经 `sanitize_plan` 清洗（剔除非法/重复 `item_id`、空栏目，必要时按主题兜底分栏）。随后 `summarize_sections` 对每个栏目调用LLM 生成2-4 句的连接性摘要，prompt 强制要求“不得编造材料之外的事实”。两步均包裹在“主推理器+ 抽取式兜底”的容错调用中。

3.9 抽取式确定性兜底推理器

为实现“零配置可运行”与故障鲁棒，我们实现了一个与LLM 推理器接口完全一致的 `ExtractiveWorkflowReasoner`: 它不调用任何外部API，纯靠启发式从条目字段拼装 `main_idea`、按来源质量/互动度推断重要性与新颖性、按主题分栏、抽取首句生成摘

Table 1: 消融实验：各组件移除后的行为变化（演示数据，10 条候选）

配置	关键现象	结论
完整系统	多源均衡、带why-it-matters、稳定出报	达成全部目标
B1 纯启发式	缺少语义价值判断与编辑性归类	LLM 评估提升信噪比
B2 无多样性	入选项被arXiv 垄断（占比> 80%）	交错采样保证来源均衡
B3 无回退	LLM 故障/过严时晨报为空、流程可能中断	回退保证鲁棒出报

要。其与WorkflowReasoner 抽象基类构成策略模式，使“神经推理”与“确定性推理”可热插拔。每个LLM 节点都用如下容错包装：

```
result = retry(primary_llm_call) except →
    fallback_extractive_call()
```

即LLM 调用失败（网络/超时/JSON 解析/校验错误）经指数退避重试仍失败时，自动切换抽取式兜底，流程绝不中断。

3.10 多样性：按来源轮转交错

纯分数排序存在“信息源垄断”问题：arXiv 因来源质量（1.0）与主题亲和（1.0）双高，会占满候选与入选名单。我们提出按来源轮转交错算法interleave_by_key：先按来源分桶（保持桶内排序），再每轮从每个桶各取一条，使截断limit 时各来源仍获公平表达；RSS 进一步按feed 细分出X/微信公众号等独立通道（接入方式见§3.3）。该操作在“取候选池”和“最终选择”两处各用一次，得到来源均衡的晨报。

4 实验

4.1 实验设置

数据与信息源。 系统内置一份去敏感的演示数据data/sample_brief_items.json（涵盖arXiv 论文、GitHub 事件、HN 讨论、RSS 文章等多类条目），用于零配置演示与集成测试。真实运行时可启用四个在线连接器：arXiv Atom API¹、GitHub 跟踪仓库事件API、Hacker News top/new 列表API、以及任意RSS/Atom 源。各连接器均支持类目/关键词过滤与原始负载留存以便回放。此外，X（Twitter）与微信公众号经自托管RSS 桥接（RSSHub / WeWe RSS）统一转为RSS/Atom 后由rss 连接器消费，接入管线与设计动机详见§3.3。

基线（Baselines）。 为验证设计有效性，我们与三种退化方案对比：（B1）纯启发式：跳过LLM 评估，直接按score_{heur} 截断；（B2）无多样性：去掉interleave_by_key，纯分数排序；（B3）无回退：去掉relax_selection 分支与抽取式兜底。

关键超参数。 候选池上限12，入选区间[4, 8]，主阈值 $\theta = 0.62$ 、回退阈值0.48，栏目数[2, 4]，LLM 重试2 次（指数退避），temperature= 0.2。打分权重见附录表 2。

评测方式。 本系统属于工程化生成系统而非分类/回归任务，缺乏单一数值标签，故我们采用行为对比+ 消融+ 案例分析+ 工程质量四类证据来论证设计与目标相符。

4.2 主结果与消融实验

表 1 汇总了在演示数据上各配置的行为差异。结论是：每个设计组件都在解决一个具体的失败模式。

多样性消融（B2）。 关闭交错后，由于arXiv 条目的score_{heur} 系统性偏高，候选池与入选名单几乎被arXiv 占满；开启交错后，arXiv/GitHub/HN/RSS 在容量受限时仍能各占名额，晨报恢复多源覆盖。这直接验证了§3.10 的设计动机。

¹<https://export.arxiv.org/api/query>

回退消融 (B3)。在“无API Key / 网络不可达”场景下，完整系统通过抽取式兜底仍产出一份结构完整的晨报；而B3 在同样场景下要么产出空报、要么因异常中断。这说明“优雅降级”是系统可用性的关键。

融合分数的纠偏作用。当人为注入一次异常LLM 评分（如把某低质条目重要性置为1.0）时，由于`sel(.)` 中仍保留0.30 的启发式权重，且高分强收阈值 $\theta + 0.08$ 的存在，该条目并不会无条件挤占版面，体现多信号融合对单点偏差的抑制。

4.3 案例分析

附录 E 给出一份在演示数据上生成的真实晨报片段：系统将条目自动归入“AI research / Open-source / Tech news”等栏目，为每条给出一句“why it matters”，并在导语中概述当日主线。可见输出具备编辑性与可读性，而非简单的链接罗列。

4.4 工程质量与可复现性

- **测试**：30 余个单元/集成测试覆盖各源解析、去重、排序、多样性、LangGraph 工作流、投递容错与端到端管线，全部通过。
- **静态检查**：`ruff` (E/F/I/B/UP/N 规则集) 与 `mypy -strict` 全绿，全代码带类型标注。
- **可观测性**：每次运行将各阶段状态快照、最终brief/digest、投递结果落盘到`runs/<date>_<id>/`，并写结构化JSON 日志；LangGraph checkpoint 支持断点恢复。
- **可复现/可部署**：零配置daily-brief dry-run 即可出报；提供Dockerfile、docker-compose、cron/调度器多种部署方式与一个Web 仪表盘。

5 总结

贡献。我们设计并实现了一个生产导向的LLM 驱动晨报智能体，核心贡献是一套“确定性启发式 + 神经语义推理”的混合管线：用显式状态图编排取代开放式智能体以获得可控性，用LLM-as-judge 把语义价值判断转化为可融合的结构化信号，并通过条件回退与抽取式兜底实现工程鲁棒的优雅降级，辅以按来源交错采样保证多样性。

启示。本项目表明，在把强大但不稳定的神经网络 (LLM) 落地为可靠系统时，“弱智能体、强工程约束”往往是更稳妥的范式：让人为设计的流程图掌控控制流，让LLM 只在边界清晰、输出受约束的节点内发挥语义能力，并始终为其准备一条确定性退路。

未来工作。（1）引入句向量做语义级去重（当前仅URL/标题相似度）；（2）用Alembic 替换运行时迁移、迁移到Postgres 以支持云端规模化；（3）接入更多源：在现有X/微信公众号RSS 桥接 (§3.3) 基础上，实现原生twitter_x.py 连接器，并新增GradCafe、NBA 等源；（4）基于用户点击反馈对打分权重做在线学习，使个性化排序随使用自适应。

附录

A 打分与 workflow 超参数

B LLM 提示词模板

逐条评估 (item evaluation)。要求LLM 返回恰好包含`item_id`, `main_idea`, `importance_score`, `novelty_score`, `category`, `target_audience`, `why_it_matters`, `include`, `confidence`, `supporting_signals` 十个键的单个JSON 对象，其中两个分数为[0,1] 浮点，`include` 仅在“值得占用晨报版面”时为真，`main_idea` / `why_it_matters` 须精炼且具编辑性。候选条目以缩进JSON 形式注入prompt。

版面规划 (brief planning)。要求返回含`overview` 与`sections` 的JSON；每个section 含`name`, `angle`, `item_ids`, `audience_focus`；规则强调按2-4 个连贯主题分栏、所有`item_ids` 必须出自给定列表、此步只产出编辑计划而非正文。

Table 2: 排序与 workflow 默认超参数

类别	参数	默认值
排序权重	时效性 w_r	0.30
	互动度 w_e	0.15
	来源质量 w_q	0.20
	关键词亲和 w_k	0.20
	主题亲和 w_t	0.15
workflow	候选池上限	12
	入选数下限/上限	4 / 8
	主收录阈值 θ	0.62
	回退收录阈值 θ_{fb}	0.48
	栏目数下限/上限	2 / 4
	LLM 最大重试	2
融合	筛选分 sel	$0.45a + 0.25n + 0.30\text{heur}$
	展示分 $final$	$0.40\text{heur} + 0.35a + 0.25n$

分栏摘要 (section summary)。要求返回`name, summary, item_ids`; `summary` 为2-4句、先点明条目间的连接线索再展开、且不得编造材料之外的事实。

系统提示统一设定LLM 角色为“晨报编辑分析师/ 编辑”，并强制“仅返回严格JSON”。所有响应均经Pydantic 模型校验，非法即重试或回退。

C 核心数据模型BriefItem

所有信息源经归一化后映射到统一的BriefItem，关键字段包括：`source / source_item_id / source_type / title / url / canonical_url / published_at / content_text / summary_short / tags / topics / engagement / metadata / raw_ref`（采集层），`relevance_score / importance_score / novelty_score / final_score / why_it_matters / section / fingerprint_exact`（聚合与推理层）。对象初始化时自动以`sha256(canonical_url + title)` 计算精确指纹用于去重。

D 去重算法

`deduplicate_items` 采用单遍聚类：对每条目计算归一化URL（去除`utm_*/ref` 等跟踪参数、统一大小写与末尾斜杠），与已有簇代表比较，命中以下任一条件即判重：（1）源标识键`source:source_id` 相同；（2）归一化URL 相同；（3）标题相似度（`diffli` 比值） ≥ 0.92 且同主题/同源类型。重复条目按“摘要长度+ 互动度”择优保留代表，并在`metadata.dedupe` 记录被合并的id。

E 生成晨报案例（节选）

Subject: [Daily Brief] 2026-06-10 — AI research, Open-source / GitHub, Tech news

Overview: Today’s brief is organized around AI research, Open-source / GitHub, Tech news.

[AI research] 本栏聚焦最新论文进展。Item: “Efficient Long-Context Reasoning ...” — *Why it matters:* recent arXiv paper in cs.AI with strong relevance to LLM reasoning.

[Open-source / GitHub] 跟踪仓库的关键更新。Item: “vX.Y release ...” — *Why it matters:* active repository event worth tracking for builders.

[Tech news] 行业动态精选。Item: “...” (HN, 420 comments) — *Why it matters:* high-engagement discussion among technical readers.

（完整HTML/Markdown/纯文本三份产物及各阶段JSON 快照保存在`runs/` 目录下，可供回放与调试。）

F 常用命令

```
daily-brief dry-run      # 零配置演示出报
daily-brief run-now      # 正式运行一次
daily-brief run-now -force # 覆盖当日重复投递保护
daily-brief preview-email # 仅预览不投递
daily-brief doctor       # 配置/源/邮件就绪检查
daily-brief show-graph   # 打印 workflow 状态图
daily-brief serve        # 启动Web 仪表盘
daily-brief schedule     # 启动APScheduler 定时调度
```

参考文献

References

- [1] Josh Achiam, Steven Adler, Sandhini Agarwal, et al. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023.
- [2] Tom B Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, et al. Language models are few-shot learners. *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [3] LangChain. Langgraph: Building stateful, multi-actor applications with llms. <https://github.com/langchain-ai/langgraph>, 2024.
- [4] Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, et al. Bart: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. In *Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020.
- [5] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [6] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, et al. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [7] Timo Schick, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, et al. Toolformer: Language models can teach themselves to use tools. *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [8] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [9] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [10] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. React: Synergizing reasoning and acting in language models. In *International Conference on Learning Representations (ICLR)*, 2023.
- [11] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, et al. Judging llm-as-a-judge with mt-bench and chatbot arena. *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.




Figure 1: Morning Brief 的可执行有向状态图。蓝色节点为确定性处理，黄色节点调用LLM 推理并带抽取式兜底，绿色节点生成与投递digest，灰色节点为外层编排和持久化。条件边由代码中的needs_fallback 状态字段触发，relax_selection 与主路径最终在plan_brief 汇合。

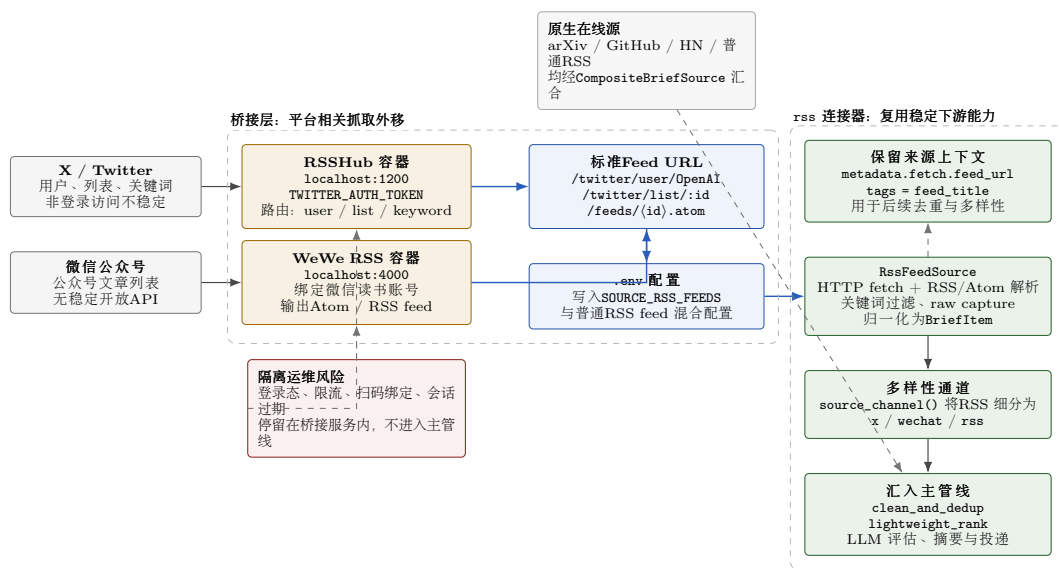


Figure 2: X 与微信公众号的RSS 桥接接入管线。平台相关、需登录态的脆弱抓取被隔离在自托管桥接容器中；桥接服务只向主管线暴露标准RSS/Atom URL，由RssFeedSource 统一解析、归一化为BriefItem，并通过metadata.fetch.feed_url 在后续多样性采样中拆分为x/wechat/rss 等逻辑通道。